Continuous-пилот · дельты к baseline

Две связанные правки. 1 и 2 — независимые повторы; их результаты показаны отдельно.

Размер production-дифа

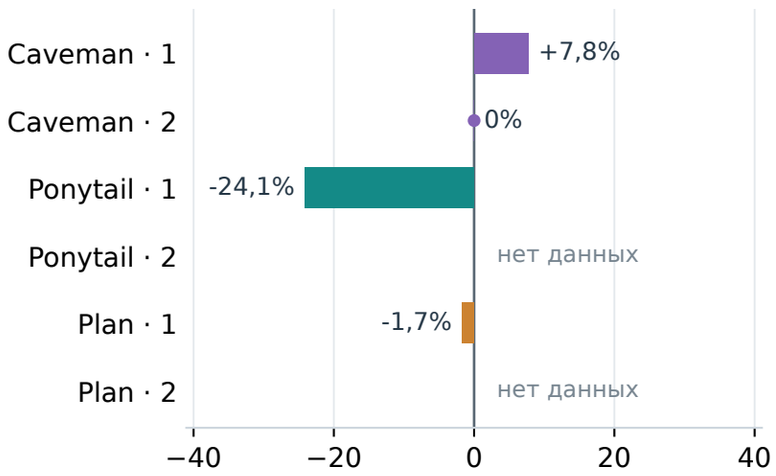

Baseline 1 / 2: 116 / 104

Чистый прирост production-кода

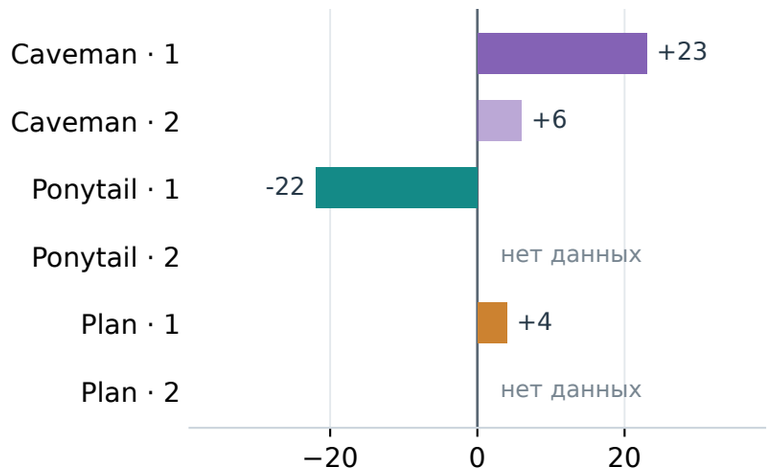

Baseline 1 / 2: 80 / 70

Output: planner + executor

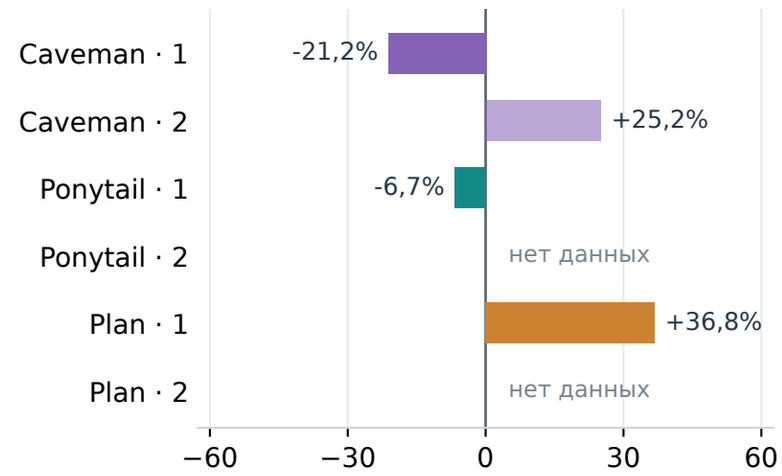

Baseline 1 / 2: 18680 / 15133

Input, включая cached input

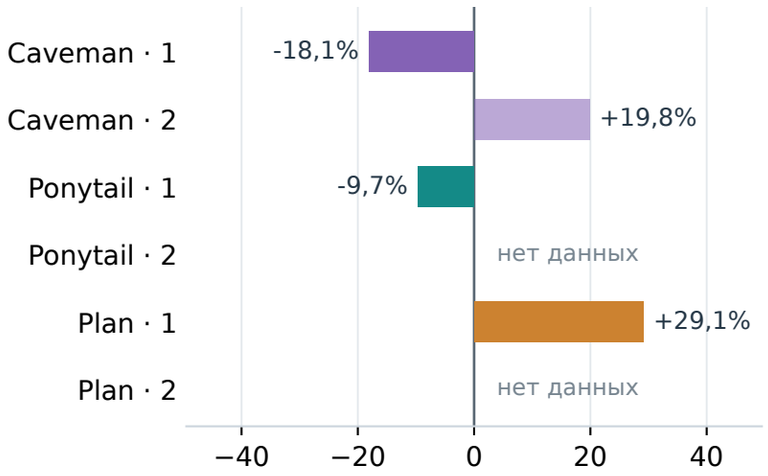

Baseline 1 / 2: 1670856 / 1283167

Input без cached input

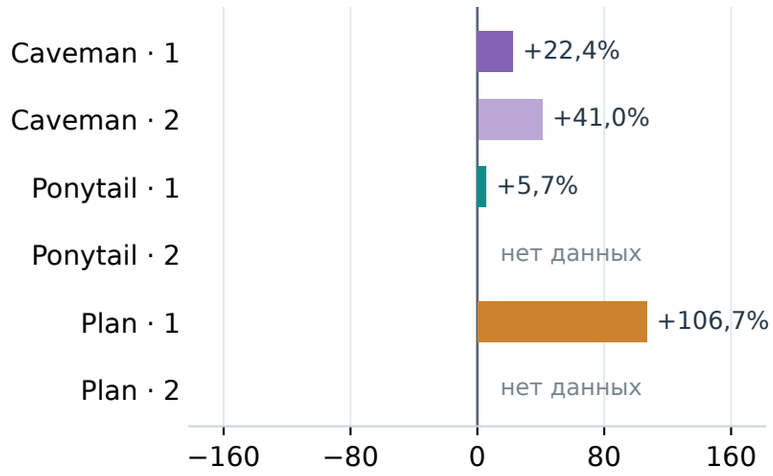

Baseline 1 / 2: 96584 / 111583

Время: planner + executor

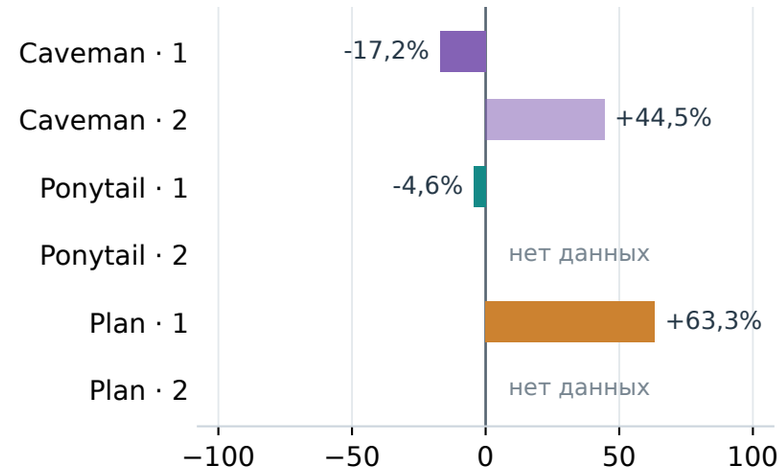

Baseline 1 / 2: 398,8 / 417,6

Δ = подход − baseline; Δ% = 100 × Δ / baseline того же повтора. Меньше не обязательно лучше.
Завершено 12/16 правок; все приняты grader. Нет данных — незавершённый повтор, не ноль.

Sonar · дельты финального снимка

Каждый подход сравнивается с baseline своего повтора.

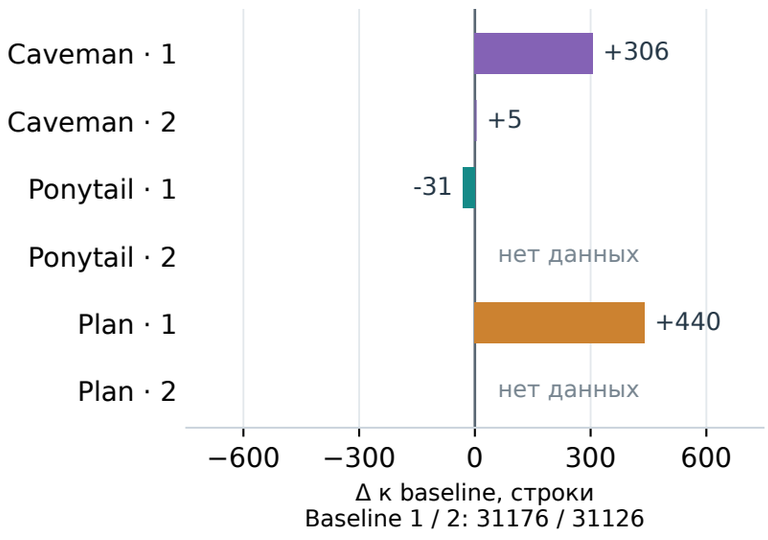

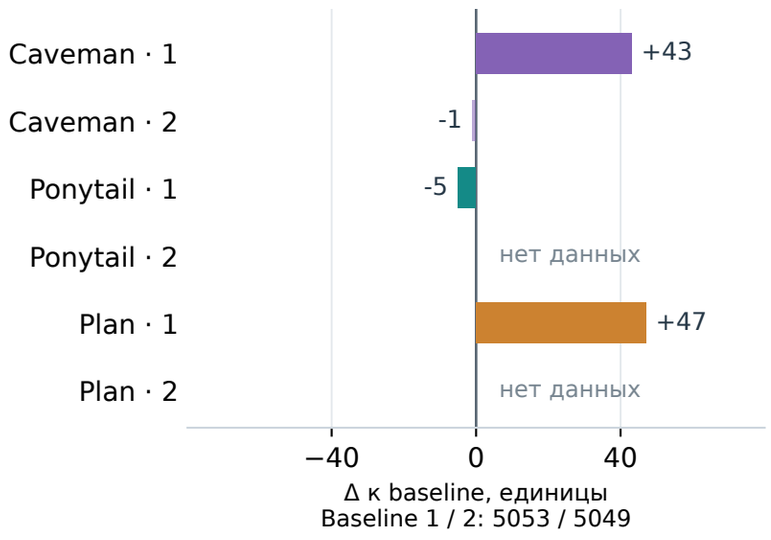

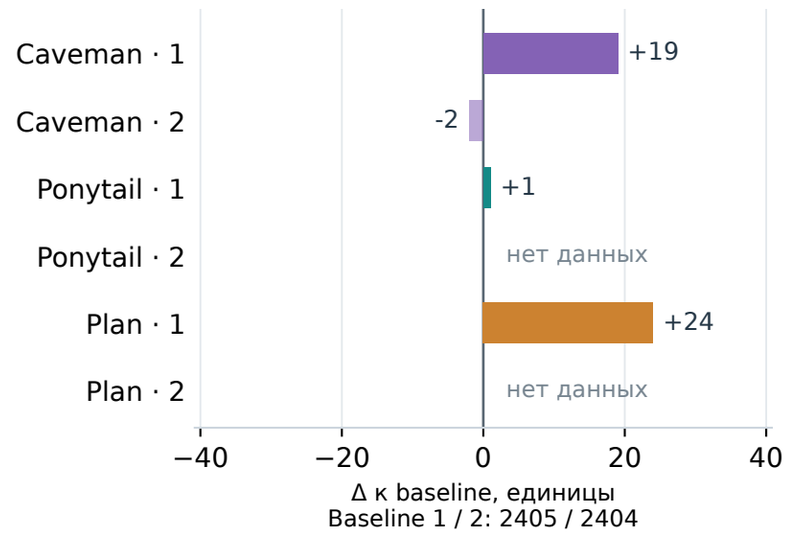

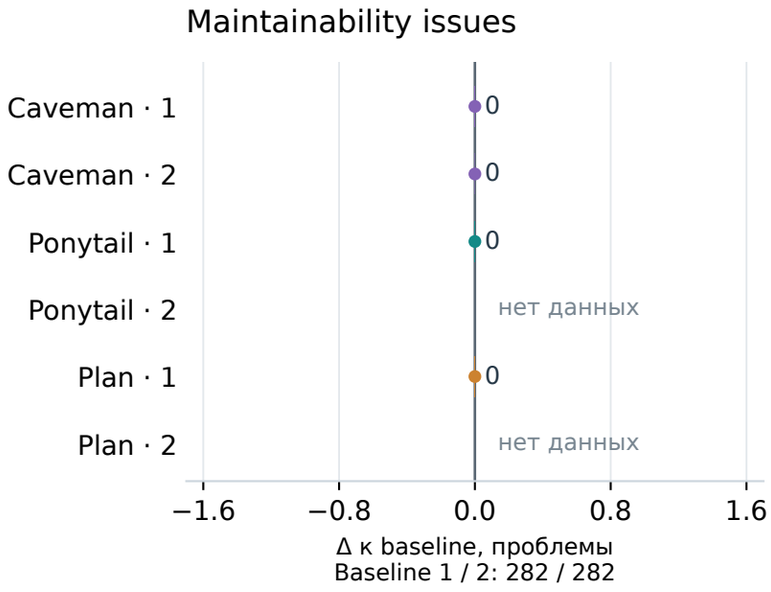

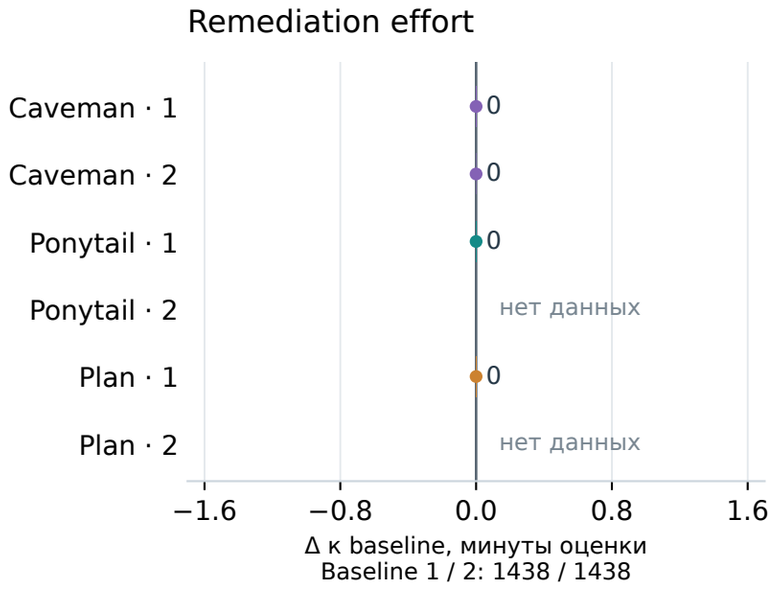

Sonar включает различающийся inline test-код; это не production-only оценка качества.
Remediation effort — оценка анализатора, не измеренное время работы человека. Нулевые значения отмечены точками.

Накопление изменений в одном repository

Churn сравнивается с исходным commit. Output суммируется по завершённым шагам.

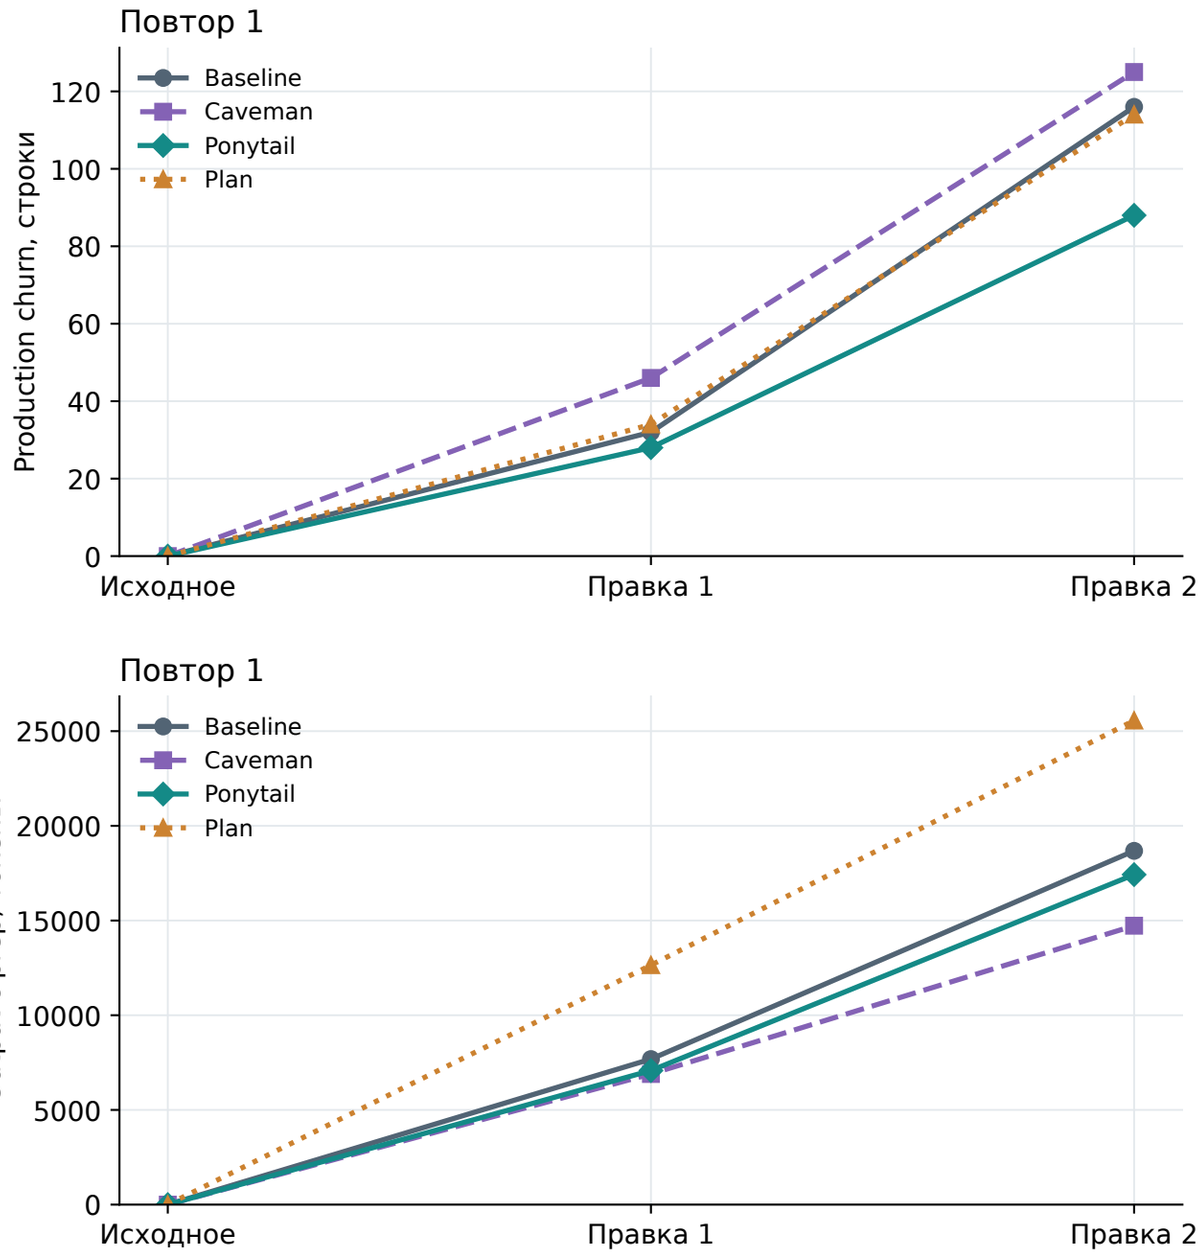

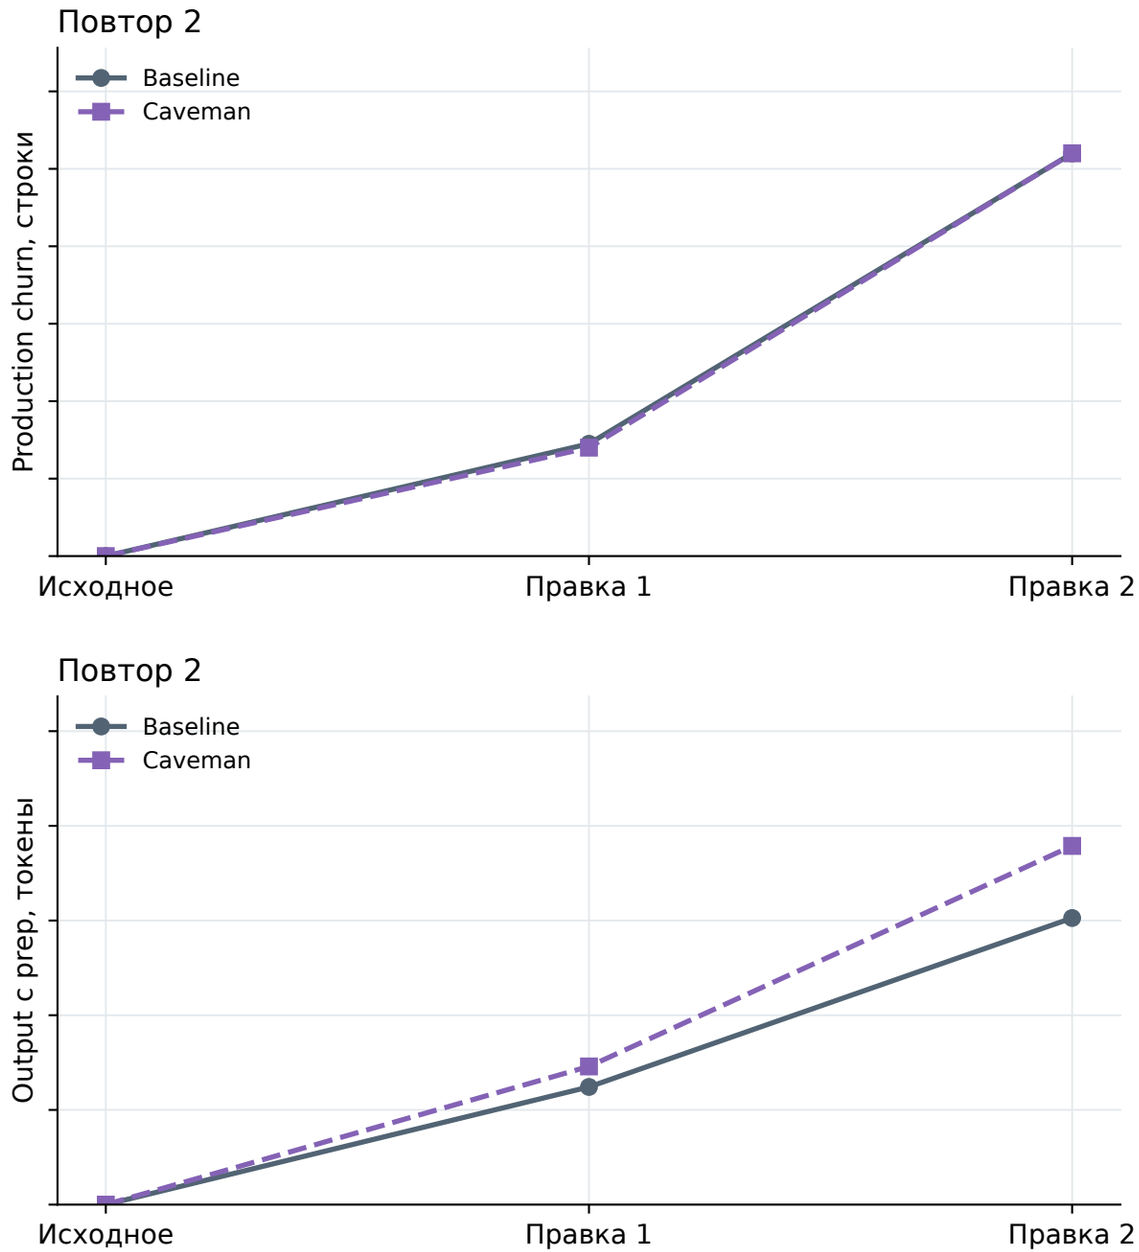

Две точки после исходного состояния не доказывают долгосрочный тренд. Показаны только завершённые траектории.

Прежние одношаговые trials · свой baseline для каждой фазы

Phase 2: планирование. Phase 3: навыки. Один trial на подход, без усреднения между фазами.

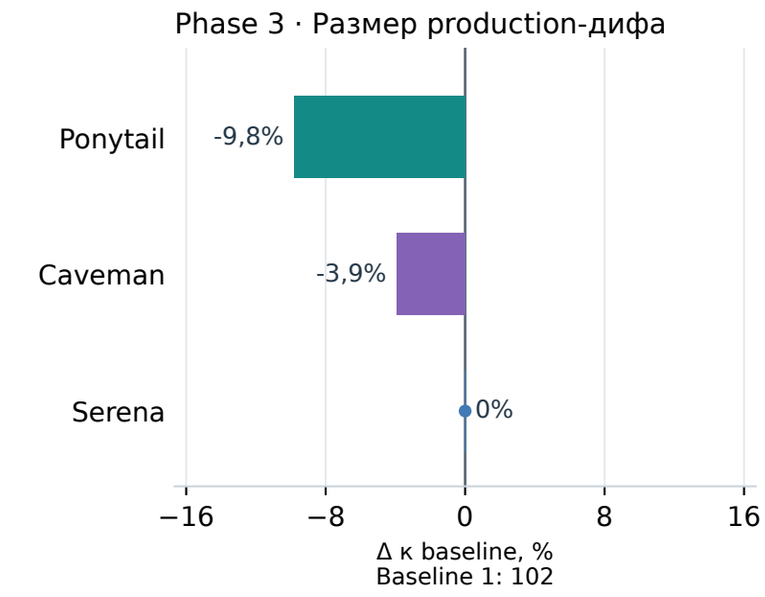

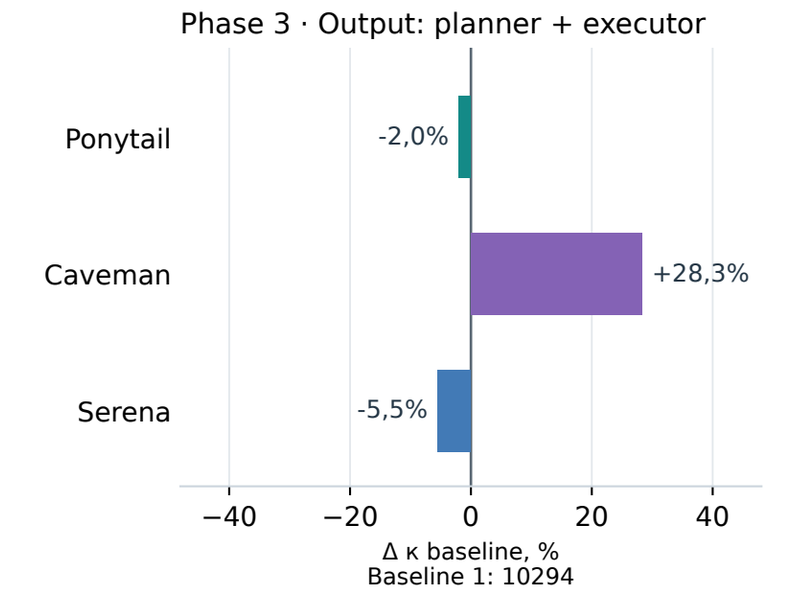

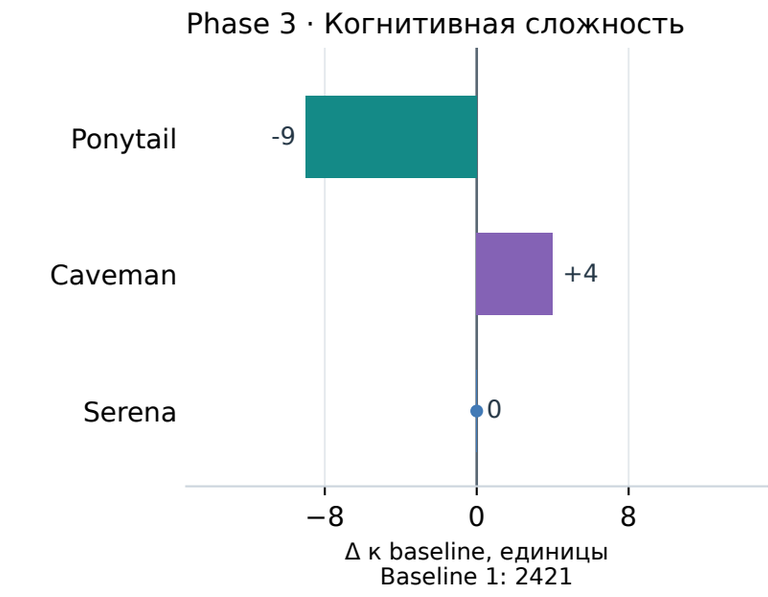

Serena: 0 measured MCP calls; её результат не показывает эффект реального использования Serena.
Sonar включает тесты. Все показанные trials приняты grader; небольшой пилот не даёт статистического рейтинга.